


機器學習 HW1 313512009 電控 施丞蔚

一、scatter plot

我利用 python 的 matplotlib 套件繪製出六張 scatter plot 來對資料分佈情況進行分析，結果如下六圖所示，圖表中三種 label 的意義分別為： Class 1 = Setosa / Class 2 = Versicolor / Class 3 = Virginica



二、Classification rate

K=1	
Combinations	Classification Rate(%)
1. Sepal length	58.00
2. Sepal width	46.00
3. Petal length	93.33
4. Petal width	95.33
5. Sepal length + Sepal width	70.00
6. Sepal length + Petal length	92.67
7. Sepal length + Petal width	87.33
8. Sepal width + Petal length	92.00
9. Sepal width + Petal width	93.33
10. Petal length + Petal width	95.33
11. Sepal length + Sepal width + Petal length	92.67
12. Sepal length + Sepal width + Petal width	92.67
13. Sepal length + Petal length + Petal width	94.67
14. Sepal width + Petal length + Petal width	96.67
15. Sepal length + Sepal width + Petal length + Petal width	94.67

K=3	
Combinations	Classification Rate(%)
1. Sepal length	62.67
2. Sepal width	46.00
3. Petal length	94.00
4. Petal width	96.00
5. Sepal length + Sepal width	74.67
6. Sepal length + Petal length	92.67
7. Sepal length + Petal width	94.00
8. Sepal width + Petal length	92.00
9. Sepal width + Petal width	95.33
10. Petal length + Petal width	95.33
11. Sepal length + Sepal width + Petal length	92.67
12. Sepal length + Sepal width + Petal width	90.67
13. Sepal length + Petal length + Petal width	95.33
14. Sepal width + Petal length + Petal width	97.33
15. Sepal length + Sepal width + Petal length + Petal width	94.00

右圖特徵號碼意義：

0: 花萼長度 (Sepal length)

1: 花萼寬度 (Sepal width)

2: 花瓣長度 (Petal length)

3: 花瓣寬度 (Petal width)

Features	K=1 Classification Rate (%)	K=3 Classification Rate (%)
0	58.00	62.67
1	46.00	46.00
2	93.33	94.00
3	95.33	96.00
4	70.00	74.67
5	92.67	92.67
6	87.33	94.00
7	92.00	92.00
8	93.33	95.33
9	95.33	95.33
10	92.67	92.67
11	92.67	96.67
12	94.67	95.33
13	96.67	97.33
14	94.67	94.00

三、CR 與散佈圖的關係

在這次作業中，使用了兩組特徵組合來繪製六張散佈圖，並應用 k-nn 算法計算 CR，結果對應到 5 到 10 項。從這些圖中可以看出，根據 Petal width 與 Petal length 的數據，每個群體的數據分佈相對於其他五張圖更加集中，因此我推測它在 CR 的表現上會是六組中最佳的，這也可從之前的結果驗證（k=1 時為 95.33% / k=3 時為 95.33%）。

從 sepal width 與 sepal length 的散佈圖中，可以觀察到 Versicolor 與 Virginica 的分佈區域重疊相當多，這意味著由於邊界不明顯，knn 在尋找最近鄰時可能會出現較高的錯誤判斷，因此如果使用這個關係作為分類器，CR 會較低，實際結果顯示 CR 約為 70.00%（k=1）及 74.67%（k=3）。

在單一特徵組合的表現分析（1 至 4）中，3 與 4 的表現均保持在 90% 以上，儘管 k 值有所調整，表現仍然穩定，性能上限約為 95% 左右。我認為這是因為單一特徵無法充分考慮所有標籤的複雜性和多變性，當特徵不明顯時（如 1 與 2），表現會顯著下降。

四、心得

這次作業給我帶來了寶貴的學習機會，讓我深入理解 K-NN 演算法的整體結構、運作原理和其特點。特別是在使用低維度的 Iris 數據集時，我發現 K-NN 演算法表現尤為出色，因為該數據集中各特徵之間的距離計算相對簡單，且具備很好的解釋性和實用性。此外，通過親自實作 K-NN 分類器，我對算法的實際運行過程有了更加全面和深入的了解。這一過程讓我清楚地看到每個步驟如何影響最終結果，也讓我更明白在實際應用中可能遇到的挑戰，以及如何調整不同參數來達到最佳效果。